Trabajo Datos Faltantes

Tema 1, MITECO

S. E. Elizabet M. R. Nicolás

November 12, 2026

Contents

1 Introducción y objetivo **2**

2 Datos **2**
2.1 Diccionario de variables 2
2.2 Distribución de los valores y nulos 3
2.3 Estructura de la ausencia 5

3 Métodos **6**

4 Resultados **6**

5 Discusión **6**

6 Reproducibilidad **6**

1 Introducción y objetivo

Los mecanismos de identificación del tipo de datos faltantes son herramientas que resultan muy útiles en muchos trabajos reales en los que se aplica la estadística. El objetivo de este trabajo es hacer tanto una exploración de los datos como un análisis de datos faltantes, indicando si el mecanismo de ausencia es MCAR, MAR o MNAR.

2 Datos

Los datos que utilizaremos en este trabajo contienen información sobre mediciones para evaluar la calidad del aire en diferentes puntos de muestreo. En nuestro caso, utilizaremos únicamente las mediciones de arsénico (As) del 2022 y 2023. Estos datos son públicos y se pueden obtener en la sección **Datos de Calidad del Aire** en la página web del MITECO.

Al cargar los datos por primera vez pudimos observar que los datos contenían 38 variables de tipo `chr` para identificar cada una de las mediciones, de las cuales las 31 variables llamadas `DXX` corresponden a cada uno de los días del mes. Debido a esto, la variable `D31` tendrá un nulo en los meses que tengan 30 días. De manera similar, en febrero habrá nulos en los días 30 y 31, además de el 29 en años bisiestos. Es decir, que todas las ausencias son reales, pero estas últimas que tratamos son sistemáticas, por la forma de guardar los datos. El resto de ausencias son intrínsecas a los datos.

Dado que la falta de estos valores se da únicamente por la forma de guardar los datos, decidimos convertir las 31 variables en una columna `valor` (de tipo `numeric`) y crear a su vez una columna `fecha` (de tipo `Date`) a partir de los valores de `ANNO`, `MES` y `DXX`, de manera que se eliminan los días que no existen. Podemos observar que `valor` es la única variable con nulos mediante `colMeans()`:

```
##      provincia      municipio       estacion punto_muestreo          fecha
##      0.0000000      0.0000000      0.0000000      0.0000000      0.0000000
##          valor
##      0.7281841
```

Además, convertimos las variables `provincia`, `municipio`, `estacion`, `punto_muestreo` a `factor`.

2.1 Diccionario de variables

A continuación se muestra una tabla de guía para las variables del *tibble* `diario_as`.

Variable	Descripción
`provincia`	Código INE de la provincia (2 dígitos, p. ej. 15 = A Coruña, 28 = Madrid).
`municipio`	Código INE del municipio dentro de la provincia (3 dígitos). Para identificarlo del todo hay que combinarlo con `provincia`.
`estacion`	Número de la estación de medición dentro del municipio. Una estación es una caseta con varios equipos.

Variable	Descripción
`punto_muestreo`	Identificador del equipo concreto. Suele tener la forma `códigoEstación_magnitud_técnica`: provincia + municipio + estación, el contaminante y un código del método de análisis. Una estación puede tener varios puntos.
`fecha`	Fecha en la que se realizó la observación.
`valor`	Concentración media diaria del arsénico. Se mide en ng/m^3.

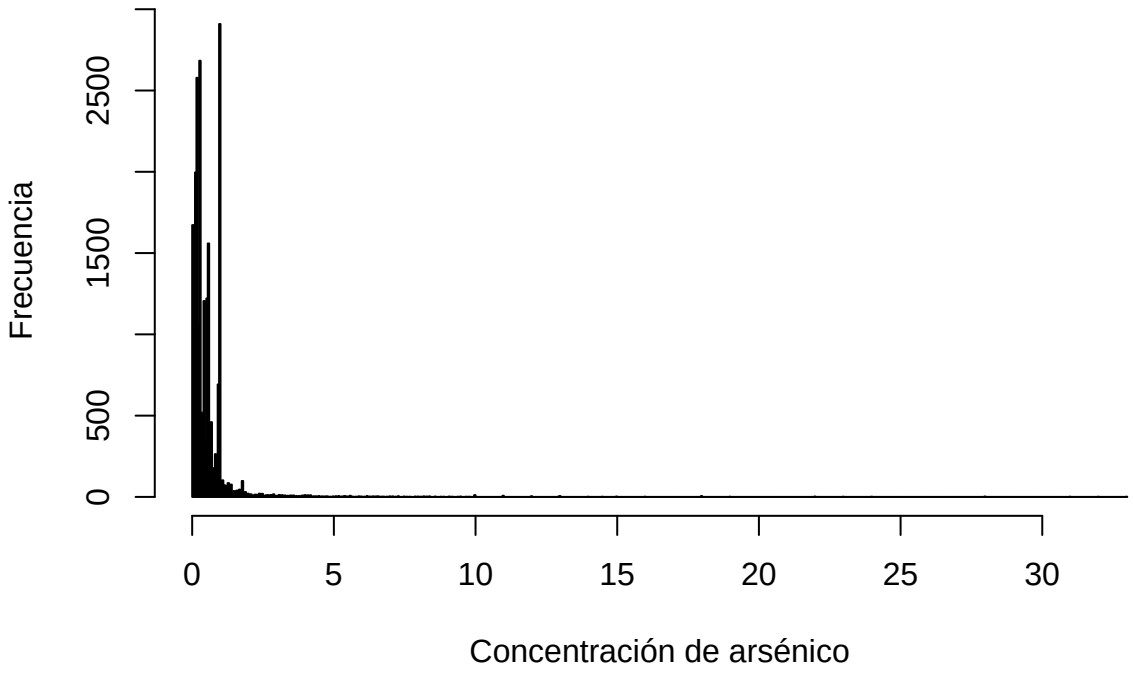
2.2 Distribución de los valores y nulos

Comenzaremos mostrando las estadísticas generales del valor medio de la concentración diaria de arsénico:

```
##    provincia       municipio        estacion           punto_muestreo
##  8      :13870   19     : 5993   1      :21833   01059009_17_M:  730
##  12     : 6570   22     : 2190   2      : 9980   02003002_17_M:  730
##  46     : 5840   65     : 2190   6      : 7635   03002002_17_M:  730
##  3      : 4380   87     : 1825   4      : 6386   03009006_17_M:  730
##  28     : 3619   16     : 1793   5      : 4745   03014006_17_M:  730
##  21     : 2920   32     : 1765   3      : 4472   03065006_17_M:  730
##  (Other):46891   (Other):68334   (Other):29039   (Other)      :79710
##      fecha                valor
##  Min.   :2022-01-01   Min.   : 0.0000
##  1st Qu.:2022-07-02   1st Qu.: 0.1810
##  Median :2022-12-27   Median : 0.3300
##  Mean   :2022-12-28   Mean   : 0.5571
##  3rd Qu.:2023-06-23   3rd Qu.: 0.7000
##  Max.   :2023-12-31   Max.   :33.0000
##                       NAs    :61233
```

La variable de estudio `valor` tiene, por tanto, un rango de valores entre 0 y 33, con media 0.5571 y mediana 0.33. Además, cuenta con 61233 nulos.

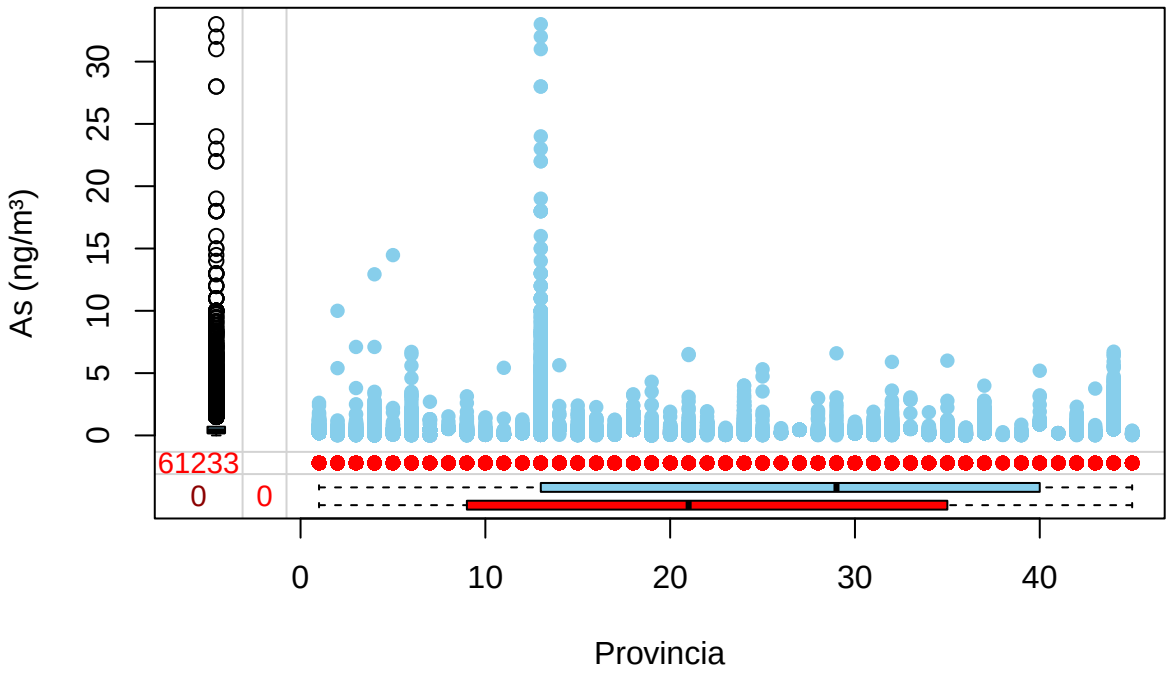
Si mostramos la distribución de los valores de la misma, observamos que efectivamente, la mayoría de valores se aproximan al 0.



La función `mice::md.pattern()` no aporta mucha información útil, ya que solo contamos con una variable, así que no nos molestaremos en incluirla. Igualmente, dentro de esta variable podemos ver el conteo de nulos, por ejemplo por año:

```
##          n observados ausentes porcentaje_NA
## 2022 42588      11549    31039         72.88
## 2023 41502      11308    30194         72.75
```

Podemos visualizar también la distribución temporal de nulos.



De esta última gráfica podemos sacar que los nulos se encuentran a lo largo de todo el rango de valores.

2.3 Estructura de la ausencia

Podemos también realizar un análisis de los puntos de muestreo, para comprobar si existe alguno que no contenga mediciones nunca, para poder descartarlo.

```
##   n_puntos n_puntos_sin_valores
## n      149                    0
```

Concluimos, por tanto, que no existen puntos de muestreo sin ningún valor.

A continuación, observaremos la distancia entre las mediciones, para intentar descubrir si existe algún patrón de medición (diario, semanal, etc.).

```
## # A tibble: 10 x 2
##      dif     n
##    <int> <int>
##  1     2  7473
##  2     1  6987
##  3     6  2510
##  4     3  1384
##  5     5  1094
##  6     4  1084
##  7     8   516
##  8    10   271
##  9     9   270
## 10     7   208
```

Test de Little para MCAR:

```
## # A tibble: 1 x 4
##   statistic    df p.value missing.patterns
##       <dbl> <dbl>   <dbl>            <int>
## 1     1074.     5       0                2
```

3 Métodos

4 Resultados

5 Discusión

6 Reproducibilidad