Trabajo 2: Datos faltantes e imputación

Análisis Estadístico de Datos Complejos · UDC

Curso 2026–2027

Objetivo y organización

Realizar por parejas un estudio aplicado sobre datos faltantes, utilizando métodos de los Temas 2 y 3 y, cuando proceda, sus extensiones. Cada pareja tendrá asignados un problema, un conjunto de datos y una técnica principal. Los detalles de los datos, las variables, los períodos y las comparaciones se facilitarán en clase o por Teams.

Los trabajos podrán abordar exploración, mecanismos de ausencia, contrastes, imputación, regresión o clasificación, con datos univariantes o multivariantes, series temporales, datos espaciales o de panel, o datos censurados.

La mitad de las parejas realizará una presentación oral de 8 minutos de este trabajo; la otra mitad presentará oralmente el trabajo de análisis de datos funcionales. Se indicará con la asignación.

Datos

Se priorizarán conjuntos ambientales compartidos, con diferentes estaciones, períodos y variables. De esta forma, dos parejas podrán usar datos relacionados sin realizar el mismo estudio. En la medida de lo posible, se procurará que los mismos datos sirvan también para el trabajo de análisis de datos funcionales.

Fuente	Posibles unidades y variables	Aplicaciones
AEMET	Una o varias estaciones; uno o varios años; temperatura, precipitación, viento, etc.	Diagnóstico de ausencias; imputación multivariante, temporal o espacial
Calidad del aire (MeteoGalicia / MITECO)	Concentraciones de contaminantes e índice de calidad del aire (ICA)	Ausencias de contaminantes, imputación y clasificación de categorías
MeteoGalicia	Estaciones y períodos seleccionados; variables meteorológicas	Comparación de estaciones, imputación y modelización
OMIE / ESIOS *(alternativos)*	Datos energéticos horarios y variables auxiliares	Amputación controlada e imputación; regresión o clasificación
Ozono (Yarner Wood)	Mediciones horarias, resúmenes diarios, ozono y otros contaminantes	Ausencias aisladas y por bloques; imputación; regresión o clasificación de niveles

Fuente	Posibles unidades y variables	Aplicaciones
Otros *(propuestos por la pareja)*	Conjuntos con ausencias reales o generadas, previa aprobación	Según la pregunta planteada

Cada pareja obtendrá los datos asignados desde su fuente, lo que puede requerir solicitar una clave de API gratuita o descargar los ficheros publicados. Hay que distinguir las ausencias originales de las que se introduzcan artificialmente, y los períodos sin cobertura de una estación (por ejemplo, antes de su instalación) de los valores realmente perdidos.

Propuesta de temas

Se plantean 15 temas para un máximo de 15 parejas. Son orientativos: para cada pareja se concretarán un conjunto de datos, una o varias variables objetivo y un procedimiento de comparación.

Nº	Tema	Paquetes R orientativos	Cuestión principal
1	Exploración y mecanismos MCAR/MAR/MNAR	`naniar`, `VIM`, `mice`	¿Dónde faltan datos, de qué depende la ausencia y cómo afecta al análisis?
2	Test de Little y alternativas	`naniar`, `MissMech`	¿Qué permite contrastar realmente MCAR y cuáles son las limitaciones del test?
3	Imputación múltiple	`mice`	¿Cómo influyen el modelo de imputación, las variables auxiliares y el tipo de respuesta?
4	EM, verosimilitud e imputación múltiple	`Amelia`, `mice`	¿Qué diferencias aparecen entre métodos y en la incertidumbre inferencial?
5	Bosques aleatorios para imputar	`missForest`, `missRanger`	¿Mejora la reconstrucción frente a métodos más sencillos? ¿Qué ocurre con la variabilidad?
6	Imputación por vecinos próximos	`VIM`	¿Cómo afectan el número de vecinos, las escalas y las variables utilizadas?
7	Imputación con relaciones no lineales	`mice`, `mgcv`	¿Cuándo conviene incluir relaciones no lineales o modelos apropiados al tipo de variable?
8	Imputación de variables categóricas	`mice` (`logreg`, `polyreg`, `polr`), `missForest`	¿Cómo imputar categorías y niveles ordenados sin perder sus proporciones ni sus asociaciones?
9	Imputación en series temporales	`zoo`, `imputeTS`, `KFAS`	¿Qué ocurre con huecos horarios aislados frente a bloques consecutivos?
10	Imputación entre estaciones	`climatol`, `gstat`	¿Qué aporta la información espacial o de estaciones vecinas?
11	Regresión con datos incompletos	`mice`, `stats`	¿Cómo cambian coeficientes, errores estándar y predicciones al tratar las ausencias?
12	Clasificación con predictores incompletos	`mice`, `rpart`, `randomForest`	¿Cómo cambian las predicciones y las métricas al imputar? ¿Se evita la fuga de información?

Nº	Tema	Paquetes R orientativos	Cuestión principal
13	Clasificación de niveles con ausencias (ICA, umbrales de ozono)	`mice`, `missForest`, `rpart`	¿Es mejor imputar las concentraciones y clasificar después, o imputar directamente la categoría?
14	Imputación en el entorno *tidyverse*	`naniar`, `simputation`, `recipes`	¿Qué ofrecen los flujos *tidy* frente a `mice`, y qué riesgos tienen (imputación única, fuga de información)?
15	Comparación de técnicas	Paquetes anteriores según el caso	¿Qué método resulta preferible bajo distintos patrones y porcentajes de ausencia?

Se podrán proponer otros métodos o paquetes en R, previa aprobación, si responden a una pregunta concreta y tienen una comparación adecuada. `climatol` podrá estudiarse especialmente con redes meteorológicas; su uso no será obligatorio para todos los equipos. Cualquier tema puede ampliarse con un contraste de MCAR (tema 2) aplicado a sus propios datos.

Contenido mínimo del trabajo

1. **Introducción y objetivo.** Definir la pregunta que se quiere responder y describir brevemente el método principal, con referencias.
2. **Datos.** Procedencia, unidades, variables, período, estructura y proporciones y patrones de ausencias. Indicar si las ausencias son reales o simuladas.
3. **Métodos.** Justificar la técnica y sus parámetros; incluir al menos un procedimiento de referencia (por ejemplo, casos completos, media o mediana, interpolación o un método visto en prácticas).
4. **Resultados.** Presentar tablas y gráficos interpretables. Cuando sea posible, ocultar valores conocidos y compararlos con sus reconstrucciones, usando las mismas posiciones ocultadas para todos los métodos.
5. **Discusión.** Interpretar los resultados, los supuestos, las limitaciones y su posible impacto en el objetivo final (estimación, regresión o clasificación).
6. **Reproducibilidad.** Entregar código R ejecutable, semillas y `sessionInfo()`; documentar los datos y las transformaciones.

La técnica, el análisis, las métricas y el esquema de validación o remuestreo se elegirán de acuerdo con la naturaleza de los datos (independientes, temporales, espaciales, categóricos…) y con el objetivo del trabajo, y deberán justificarse en el informe.

Entrega y evaluación

Entrega: informe en PDF (aproximadamente 8–10 páginas, excluidos los anexos técnicos necesarios) y un `.Rmd` o scripts `.R` reproducibles. No incluir listados extensos de código en el cuerpo del informe. Citar las fuentes de los datos, los métodos y los paquetes. La fecha y el procedimiento de entrega se comunicarán en clase o por Teams.

Se valorarán el rigor estadístico, el diseño de las comparaciones, la reproducibilidad, la interpretación de los resultados y la claridad del informe.

Presentación oral (parejas designadas): 8 minutos, centrados en objetivo, método, resultados y conclusiones; los detalles de su valoración se comunicarán con la asignación. Se evaluará la calidad del análisis, no la cantidad de paquetes utilizados.

Nota: las asignaciones concretas (tema, datos, variable, estación, años, métodos comparados y fecha) se comunicarán en clase o por Teams. No es necesario que todas las parejas descarguen todas las fuentes anteriores.